JANELA DE CONTEXTO E EFICIÊNCIA DE CUSTOS

Limitações do Contexto Longo, Confiabilidade e Avaliação Experimental

Semana 02 - Aula 02

28/10/2026

<LAB365> SENAI

<LAB365>

JANELA DE CONTEXTO E EFICIÊNCIA DE CUSTOS

Limitações do Contexto Longo, Confiabilidade e Avaliação Experimental

SENAI

AGENDA

01 — Contexto nominal e contexto efetivo

02 — Lost in the Middle, Primacy e Recency

03 — Ruído, informações conflitantes e truncamento

04 — Diagnóstico de falhas e utilização das evidências

05 — Benchmarks, métricas e avaliação controlada

MAPA DA INVESTIGAÇÃO

Vamos investigar não apenas quanto cabe na janela, mas como o modelo utiliza as informações disponíveis.

01

Hipótese

Uma janela maior não garante o uso correto de todas as informações.

02

Mecanismos

Posição da informação, distratores, contradições e truncamento.

03

Quanto custa?

Testes controlados, benchmarks e métricas de recuperação.

LAB • mesmo conteúdo, três posições e múltiplos distratores.

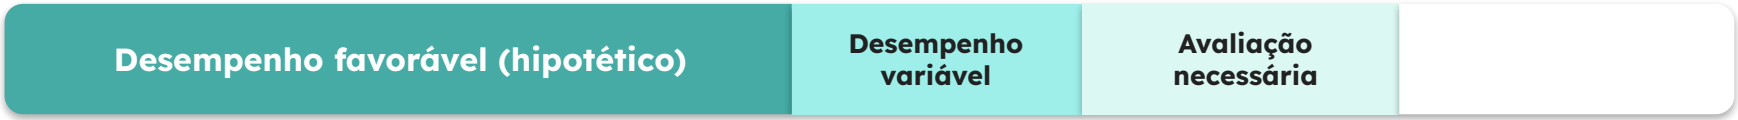
CONTEXTO NOMINAL × CONTEXTO EFETIVO

Representação conceitual: Sem dados de um modelo específico.

Capacidade nominal

Janela máxima suportada

Uso efetivo do contexto



Contextos mais curtos

Contextos mais longos

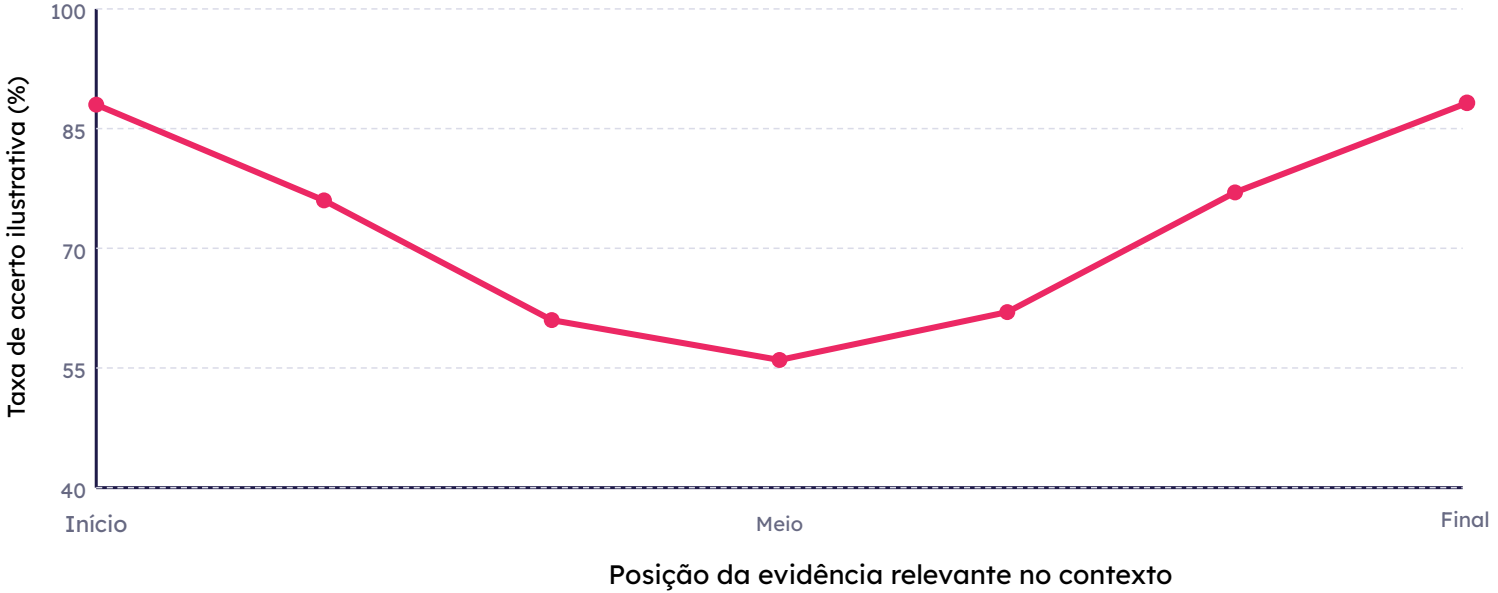
A qualidade depende da tarefa, da posição da informação e da presença de distratores.

As cores são ilustrativas: não representam uma queda medida, universal ou necessariamente monotônica.

LOST IN THE MIDDLE: QUANDO A POSIÇÃO AFETA A RESPOSTA

Em tarefas estudadas, o desempenho costuma cair quando a evidência está no meio.

Curva conceitual inspirada no padrão reportado; valores NÃO experimentais



Padrão em U

Primeiro ou último?

Nem sempre: valide em seu modelo e tarefa.

PDF
Paper

Mudar a posição de um documento pode alterar a resposta sem mudar o conteúdo.

PRIMACY E RECENCY: TESTANDO A POSIÇÃO DA EVIDÊNCIA

A mesma informação é posicionada no início, no meio e no final do contexto.

INÍCIO



Evidência próxima do começo

MEIO



Evidência no centro

FINAL



Evidência próxima do fim

Mesma pergunta, mesma evidência, posições diferentes: a qualidade da resposta pode mudar.

RUÍDO, REDUNDÂNCIA E DISTRATORES: MAIS CONTEXTO NEM SEMPRE É MELHOR

Informações irrelevantes, redundantes ou enganosas podem dificultar o uso das evidências.

Pergunta do usuário: “Comprei um curso há 9 dias e tive problemas de acesso. Ainda posso pedir reembolso?”

D1 Evidências relevantes Regra geral: até 7 dias	**D2** Informações irrelevantes Catálogo de cursos	**D3** Informações irrelevantes Informações sobre certificados
D4 Evidências relevantes Falha de acesso: até 15 dias	**D5** Informações irrelevantes Preços de outros cursos	**D6** Conteúdo duplicado Repete a regra de D1

Mais conteúdo pode aumentar o custo e dificultar a resposta. Relevância importa mais que volume.

MINI-DESAFIO: QUAL FONTE O MODELO DEVE UTILIZAR?

Três documentos descrevem o mesmo serviço, mas apresentam configurações conflitantes.

DOC A

Atualização: janeiro

Timeout = 5 s

DOC B

Atualização: março

Timeout = 10 s

DOC C

Versão vigente de produção

Timeout = 15 s

Qual valor você utilizaria para responder sobre o ambiente de produção? O que precisa verificar?

Antes de responder: verificar fonte, versão, ambiente, data e critérios de precedência.

QUANDO A RESPOSTA EXISTE, MAS NÃO É UTILIZADA

Identificar se a falha ocorreu na recuperação, na preparação do contexto ou na utilização da evidência.

Fonte
O documento contém a informação correta?

→

Recuperação
O trecho relevante foi encontrado e selecionado?

→

Contexto
A evidência chegou ao modelo sem ser removida ou truncada?

→

Resposta
O modelo utilizou corretamente a evidência disponível?

EXERCÍCIO DE DIAGNÓSTICO

Em qual etapa ocorreu a falha no uso da evidência?

Avaliar somente a resposta final esconde onde a falha realmente começou.

Não confie apenas na sensação de acerto

Um experimento controlado separa hipótese, variável e observação.

A falha se repete quando testamos sob as mesmas condições?

NEM TODO ERRO É ALUCINAÇÃO: IDENTIFIQUE A CAUSA

A classificação do erro ajuda a escolher qual intervenção testar primeiro.

Faltou evidência

A informação não foi recuperada ou foi removida do contexto.

Ação a testar: Melhorar recuperação e seleção.

Evidência ignorada

A informação estava disponível, mas não foi utilizada corretamente.

Ação a testar: Revisar organização e instruções; testar novamente.

Resposta inventada

O modelo apresentou afirmações sem suporte nas evidências disponíveis.

Ação a testar: Verificar fundamentação e permitir abstenção.

Ru et al. (2024), RAGChecker: A Fine-grained Framework for Diagnosing Retrieval-Augmented Generation

Antes de corrigir uma resposta incorreta, identifique onde a falha ocorreu e quais evidências estavam disponíveis.

SATURAÇÃO E TRUNCAMENTO: QUANDO A INFORMAÇÃO SE PERDE

Limites de contexto e geração podem causar rejeições, perda de informações ou respostas incompletas.

Entrada excede

A API pode rejeitar a requisição quando o limite é ultrapassado.

Contexto é reduzido

A aplicação pode remover mensagens ou trechos importantes.

Saída é limitada

A resposta pode ficar incompleta ao atingir o limite de tokens de saída.

Planeje como tratar limites: rejeitar, resumir, selecionar trechos ou continuar a geração.

Verifique o conteúdo enviado ao modelo e se a resposta terminou corretamente.

TESTE CONTROLADO: UMA VARIÁVEL POR VEZ

<LAB365> SENAI

Alterar várias condições ao mesmo tempo dificulta identificar o que causou a diferença nos resultados.

1. **Constante**
   Modelo, pergunta, documentos e parâmetros de geração.
2. **Variável**
   Posição da mesma evidência: início, meio ou final.
3. **Resposta esperada**
   Resposta de referência, definida antes do experimento.
4. **Métricas**
   Taxa de acerto, suporte nas evidências, tokens e latência.

Uma avaliação confiável exige condições controladas, métricas claras e resultados reproduzíveis.

NEEDLE IN A HAYSTACK: LOCALIZAR UMA AGULHA

Inserir uma informação verificável em um texto longo e avaliar se o modelo consegue recuperá-la.



Pergunta
Qual é a chave informada no texto?

Resposta esperada:
7341

Inserir

Inserir a evidência em uma posição definida.

Perguntar

Fazer a mesma pergunta em cada teste.

Validar

Medir o acerto por posição e tamanho do contexto.

É um teste útil, mas limitado: encontrar uma agulha não é raciocinar sobre o documento.

RULER: UMA AVALIAÇÃO MAIS EXIGENTE

Benchmark que amplia o desafio para além da recuperação isolada.

Recuperação

Localizar informações específicas entre vários trechos

Multi-hop Tracing

Rastrear relações entre informações ao longo de várias etapas

Aggregation

Contar frequências e agregar informações distribuídas

QA

Responder perguntas com base em evidências presentes em contextos longos

Fonte: Hsieh et al. (2024). RULER: What's the Real Context Size of Your Long-Context Language Models? — COLM 2024.

Encontrar uma informação não basta: é preciso avaliar recuperação, relações, agregação e respostas fundamentadas.

LABORATÓRIO: INVESTIGANDO RESPOSTAS INCONSISTENTES

<LAB365> SENAI

Analisar como a seleção e a organização do contexto influenciam a resposta de um LLM na prática

01

10 min

Entenda o caso

Analise a pergunta do usuário e os documentos disponíveis

02

10 min

Teste 1

Use **todos** os documentos recuperados e gere a resposta

03

10 min

Teste 2

Selecione apenas os trechos **relevantes** e gere a resposta novamente

04

10 min

Compare

Avalie a correção, a fundamentação e o uso de contexto das duas respostas

Objetivo Identificar por que uma resposta incorreta pode ser gerada com a informação correta presente na documentação e como melhorar o resultado a partir da seleção de contexto

ENTREGÁVEL: Tabela comparativa das duas configurações (todos os documentos x selecionados), com as respostas, fundamentação, uso de tokens e conclusão.

LABORATÓRIO: INVESTIGANDO RESPOSTAS INCONSISTENTES

<LAB365> SENAI

Estudo de caso: assistente de atendimento

Pergunta do usuário

"Comprei um curso há 9 dias e tive problemas de acesso. Ainda posso solicitar reembolso?"

Resposta incorreta (exemplo)

Esta é uma resposta incorreta simulada, que motivou a investigação. Os resultados dos testes não são predefinidos.

"Não é possível solicitar reembolso, pois o prazo de sete dias já terminou."

Documentos recuperados (pelo sistema)

D1	Regra geral: reembolso em até 7 dias da compra.
D2	Catálogo de cursos e modalidades.
D3	Política de certificados.
D4	Exceção por falha de acesso: até 15 dias para solicitar reembolso.
D5	Tabela de preços e formas de pagamento.
D6	Cópia da regra geral de D1.

O que você deve fazer

Teste 1 – Todos os documentos (D1 a D6)

1. Envie a pergunta do usuário junto com todos os documentos recuperados (D1 a D6) para o modelo.
2. Registre a resposta, as citações (se houver) e o uso de tokens.

Teste 2 – Apenas os trechos relevantes (ex.: D1 e D4)

1. Selecione apenas os documentos realmente relevantes (por exemplo, D1 e D4).
2. Envie a mesma pergunta para o modelo e registre a resposta, as citações (se houver) e o uso de tokens.

Compare e analise

- Qual resposta está correta?
- Quais documentos foram utilizados como evidência?
- Houve diferença no uso de tokens?
- Como a seleção de contexto influenciou o resultado?

Dica: o que considerar como resposta correta?

O modelo deve considerar a regra geral (7 dias) e a exceção de falha de acesso (até 15 dias). Como a compra foi há 9 dias, a resposta correta deve indicar que é possível solicitar o reembolso, considerando as condições da exceção (D4).

Utilize o mesmo modelo, as mesmas configurações e a mesma pergunta nos dois testes, em conversas independentes.
Os resultados dos testes podem variar. O objetivo é analisar e justificar o que aconteceu em cada caso.

EXPERIMENTO 2: DISTRATORES E VERSÕES ANTIGAS

A mesma pergunta, três configurações de contexto: evidências relevantes, ruído e informações conflitantes.

Pergunta

“Comprei um curso há 9 dias e tive problemas de acesso. Ainda posso solicitar reembolso?”

Teste A: Baseline

D1 + D4

Apenas a regra geral e a exceção vigente

D1: regra geral (7 dias)
D4: exceção vigente (até 15 dias para problemas de acesso).

Teste B: + Ruído

D1 + D4 + D2, D3 e D5

Acrescentar documentos irrelevantes

D2: D3 e **D5** são documentos relacionados, mas que não ajudam a responder a pergunta

Teste C: + Conflito

D1 + D4 + D7

Acrescentar uma versão revogada que contradiz a vigente

D7: política antiga (revogada). Estabelece que problemas de acesso também possuem prazo máximo de reembolso de 7 dias.

Compare cada cenário com o baseline. Altere apenas os documentos previstos para cada teste.

COMPARANDO RESULTADOS: CONTEXTO COMPLETO × SELECIONADO

Registre as respostas dos dois testes antes de avaliar os resultados.

Cenário	Documentos	Tokens de entrada	Latência (s)	Correção (0–2)	Fundamentação (0–2)
Lab 1 — Completo	D1–D6				
Lab 1 — Selecionado	D1 + D4				
Lab 2 — Ruído	D1 + D4 + D2 + D3 + D5				
Lab 2 — Conflito	D1 + D4 + D7				

A seleção de documentos melhorou a resposta, reduziu tokens ou preservou a qualidade com menor custo?

AULA 2: DA IMPRESSÃO À EVIDÊNCIA

Três práticas para investigar problemas de contexto com rigor

01

Controle variáveis

Mantenha as condições controladas e altere uma variável por vez.

02

Meça a resposta

Acerto, suporte nas evidências, tokens e latência.

03

Inspecione o pipeline

Fonte → Recuperação → Contexto enviado → Resposta

PRÓXIMA AULA • Como construir contextos menores, mais relevantes e seguros.

<LAB365>